

LAPORAN KARAKTERISTIK DATASET

Adult Census Income Dataset

Mata Kuliah: Machine Learning / Sains Data

Kelompok: 12

Anggota: Adam Fadlaa, Kartika Azari

1. Informasi Umum Dataset (Metadata)

Bagian ini berisi identitas dasar dan asal-usul dataset yang dipilih.

Nama Dataset	Adult Census Income Dataset
Sumber Dataset	Kaggle (mirror dari UCI Machine Learning Repository), https://www.kaggle.com/datasets/uciml/adult-census-income
Format File	.csv
Ukuran Data	32.561 baris (instances) x 15 kolom (features, termasuk target)
Tujuan Prediksi	Klasifikasi biner untuk memprediksi apakah pendapatan tahunan seseorang >50K atau <=50K USD berdasarkan data demografi dan pekerjaan

2. Deskripsi Fitur (Data Dictionary)

Dataset memiliki 15 kolom, terdiri dari 14 fitur (6 numerik dan 8 kategorikal) dan 1 kolom target (income).

No	Nama Fitur	Tipe Data	Peran	Keterangan
1	age	Numerik (Int)	Fitur	Usia individu dalam tahun
2	workclass	Kategorikal (Nominal)	Fitur	Jenis instansi/status pekerjaan (Private, Self-emp, Government, dll). Mengandung nilai '?' sebagai data hilang
3	fnlwgt	Numerik (Int)	Fitur	Final weight - bobot statistik dari sensus AS yang merepresentasikan estimasi jumlah populasi dengan karakteristik demografis serupa
4	education	Kategorikal (Ordinal)	Fitur	Tingkat pendidikan terakhir (HS-grad, Bachelors, Masters, dst.)
5	education.num	Numerik (Int)	Fitur	Representasi numerik dari tingkat pendidikan (1-16), berkorelasi langsung dengan kolom 'education'
6	marital.status	Kategorikal (Nominal)	Fitur	Status perkawinan (Married-civ-spouse, Divorced, Never-married, dll.)
7	occupation	Kategorikal (Nominal)	Fitur	Jenis pekerjaan/jabatan. Mengandung nilai '?' sebagai data hilang
8	relationship	Kategorikal (Nominal)	Fitur	Peran dalam keluarga (Husband, Wife, Own-child, Not-in-family, dll.)
9	race	Kategorikal (Nominal)	Fitur	Ras individu (White, Black, Asian-Pac-Islander, dll.)

10	sex	Kategorikal (Nominal/Biner)	Fitur	Jenis kelamin (Male/Female)
11	capital.gain	Numerik (Int)	Fitur	Keuntungan modal (capital gain) dalam USD, sebagian besar bernilai 0
12	capital.loss	Numerik (Int)	Fitur	Kerugian modal (capital loss) dalam USD, sebagian besar bernilai 0
13	hours.per.week	Numerik (Int)	Fitur	Jumlah jam kerja per minggu
14	native.country	Kategorikal (Nominal)	Fitur	Negara asal individu. Mengandung nilai '?' sebagai data hilang
15	income	Kategorikal (Nominal/Biner)	Target	Kategori pendapatan tahunan: '<=50K' atau '>50K'

3. Analisis Kualitas Data (Data Quality)

Temuan terkait anomali dan kebersihan data awal pada dataset.

Aspek Kualitas Data	Jumlah / Persentase	Temuan	Rencana Tindakan (Penanganan)
Data Hilang (Missing Values)	workclass: 1.836 (5,64%) occupation: 1.843 (5,66%) native.country: 583 (1,79%)	Tidak ada nilai NaN literal, namun data hilang direpresentasikan dengan simbol '?' pada 3 kolom kategorikal (workclass, occupation, native.country)	Ganti '?' menjadi NaN, lalu lakukan imputasi dengan modus (nilai kategori terbanyak) per kolom, atau buat kategori baru 'Unknown'
Data Duplikat	24 baris duplikat penuh (0,07%)	Terdapat 24 baris yang identik di seluruh kolom	Hapus (drop) baris duplikat sehingga tersisa 32.537 baris unik
Pencilan (Outliers)	hours.per.week: 9.008 (27,66%) capital.gain: 2.712 (8,33%) capital.loss: 1.519 (4,67%) education.num: 1.198 (3,68%) fnlwgt: 992 (3,05%) age: 143 (0,44%)	Terdeteksi melalui metode IQR (1.5xIQR). capital.gain dan capital.loss sangat menceng (skewed) karena mayoritas bernilai 0. hours.per.week memiliki proporsi outlier tinggi karena mayoritas pekerja bekerja tepat 40 jam/minggu	Untuk capital.gain/loss: biarkan apa adanya atau ubah menjadi fitur biner (memiliki gain/loss atau tidak), karena outlier bersifat alami (bukan kesalahan input). Untuk fitur lain: pertimbangkan Winsorization atau biarkan jika secara domain masuk akal

4. Statistik Deskriptif (Fitur Numerik)

Ringkasan statistik untuk keenam fitur numerik pada dataset.

Nama Fitur	Mean	Std Dev	Min	25% (Q1)	50% (Q2)	75% (Q3)	Max
age	38,58	13,64	17	28	37	48	90
fnlwgt	189.778,37	105.549,98	12.285	117.827	178.356	237.051	1.484.705
education.num	10,08	2,57	1	9	10	12	16
capital.gain	1.077,65	7.385,29	0	0	0	0	99.999
capital.loss	87,30	402,96	0	0	0	0	4.356
hours.per.week	40,44	12,35	1	40	40	45	99

5. Analisis Distribusi & Target Korelasi

Distribusi Variabel Target

Variabel target (income) bersifat tidak seimbang (imbalanced). Dari total 32.561 baris:

- Kelas '<=50K' : 24.720 baris (75,92%)
- Kelas '>50K' : 7.841 baris (24,08%)

Rasio ketimpangan sekitar 3:1, sehingga model klasifikasi yang dilatih tanpa penanganan khusus berisiko bias terhadap kelas mayoritas ('<=50K'). Diperlukan teknik seperti oversampling (SMOTE), undersampling, class weighting, atau pemilihan metrik evaluasi yang tepat (F1-score, Precision-Recall, ROC-AUC) selain accuracy.

Korelasi Antar Fitur

Berdasarkan matriks korelasi Pearson antar fitur numerik dan target (income, dikodekan 0/1):

- education.num memiliki korelasi positif tertinggi terhadap target ($r = 0,34$) - semakin tinggi jenjang pendidikan, semakin besar peluang berpendapatan >50K
- age ($r = 0,23$) dan hours.per.week ($r = 0,23$) memiliki korelasi positif moderat terhadap target
- capital.gain ($r = 0,22$) dan capital.loss ($r = 0,15$) berkorelasi positif lemah-moderat terhadap target
- fnlwgt praktis tidak berkorelasi dengan target ($r = -0,01$), sesuai ekspektasi karena kolom ini adalah bobot statistik sensus, bukan atribut personal
- Korelasi antar sesama fitur numerik secara umum lemah (di bawah 0,15), mengindikasikan tidak ada masalah multikolinearitas yang signifikan di antara fitur numerik

6. Kesimpulan Awal & Langkah Selanjutnya

Dataset Adult Census Income cukup representatif dan populer digunakan untuk tugas klasifikasi biner, namun membutuhkan beberapa tahap prapemrosesan sebelum dimasukkan ke algoritma Machine Learning, antara lain:

- Penanganan data hilang: mengganti simbol '?' pada kolom workclass, occupation, dan native.country (imputasi modus atau kategori 'Unknown')
- Penghapusan 24 baris duplikat

- Encoding variabel kategorikal (One-Hot Encoding untuk fitur nominal seperti workclass, race, native.country; Label/Ordinal Encoding untuk education yang bersifat ordinal)
- Penanganan data timpang (imbalanced) pada variabel target, misalnya dengan SMOTE, class_weight, atau resampling
- Penskalaan fitur (feature scaling) seperti StandardScaler atau MinMaxScaler untuk fitur numerik dengan skala berbeda jauh (contoh: fnlwgt vs age)
- Pertimbangan untuk men-drop atau mentransformasi fitur fnlwgt karena korelasinya sangat lemah dengan target

Dengan penanganan tersebut, dataset ini layak digunakan untuk pemodelan klasifikasi prediksi tingkat pendapatan.